

B4 輪講 2026：EX5 レポート

加藤 稔之典

2026 年 6 月 14 日

1 課題 1：学習設定の決定

本課題では、ex4 で使用した配布済み NMSTPP モデルをベースラインとして、自前で学習したモデルとの比較を行った。

対象試合には、ex4 と同様に 2017 シーズンのラ・リーガにおける「レアル・マドリード vs バルセロナ」(match id = 2565711) を選択した。本試合はクラシコとして知られる世界的にも注目度の高い試合であり、前半と後半で試合の主導権が大きく変化する特徴的な展開を示した。そのため、モデルが試合の流れをどの程度捉えられるかを評価する対象として適していると考えた。

本課題では、モデル構造、学習データ、およびハイパーパラメータの影響を調査するため、以下の 4 種類の設定を用意した。

1. モデル変更 (FMS)
2. モデル変更 + データ拡張 (FMS + Spain リーグ + England リーグ)
3. モデル変更 + ハイパーパラメータ変更 (FMS + seq.len=40)
4. モデル変更 + データ拡張 + ハイパーパラメータ変更

1.1 モデル変更の狙い

ベースラインである NMSTPP (Neural Marked Spatio-Temporal Point Process) は、イベントの発生時刻・位置・行動タイプを同時に扱う Transformer ベースの時空間モデルである。イベント系列を時系列データとして扱い、次に発生するイベントを予測することを目的としている。

一方、本課題で採用した FMS (Foundation Model for Soccer) は、大規模なサッカーイベントデータから試合展開そのものを学習することを目的として提案された基盤モデルである。

FMS は個々のイベントだけでなく、パスワークや攻撃の組み立てといった長期的な試合文脈を学習できる可能性がある。そのため、本課題では NMSTPP と比較して、より試合展開に即した予測が可能になるのではないかと考え、モデル変更を行った。

1.2 データ拡張の狙い

ベースラインでは Spain リーグのみを学習に利用していた。

しかし、単一リーグのみでは学習できる戦術パターンに偏りが生じる可能性がある。そこで、本課題では

England リーグのデータも追加し、学習データ量を増加させた。

データ拡張によって、

- より多様な攻撃・守備パターンの学習
- 未知の試合に対する汎化性能の向上
- データ不足による過学習の抑制

が期待できると考えた。

また、England リーグはプレースピードや攻撃スタイルが Spain リーグと異なる傾向があるため、多様な試合展開を学習できる可能性があると考えた。

1.3 ハイパーパラメータ変更の狙い

FMS のデフォルト設定では、直前 9 イベントを入力として次イベントを予測する (seq_len=9)。

しかし、サッカーではボール奪取からシュートに至るまでに 10~30 イベント以上が連続することも珍しくない。そのため、9 イベントのみでは攻撃全体の流れやポゼッションの意図を十分に捉えられない可能性があると考えた。

そこで本課題では seq_len を 40 へ拡張し、より長い試合文脈を考慮した予測が可能になるかを検証した。

40 という値は、典型的な攻撃シーケンス全体を概ね含むことができる長さであり、短期的なイベントだけでなく、中長期的なパス回しや攻撃構築の流れも学習できると考えたため採用した。

1.3.1 対象試合の概要

対象試合は 2017 シーズンのラ・リーガにおけるレアル・マドリード対 FC バルセロナ (match id = 2565711) である。試合はレアル・マドリードのホームで行われ、最終的に FC バルセロナが 0-3 で勝利した。

前半はレアル・マドリードが主導権を握った。開始 2 分にはクリスティアノ・ロナウドがヘディングでネットを揺らしたもののオフサイド判定となり、その後もロナウドやベンゼマを中心に複数の決定機を作った。しかし、GK テア・シュテークゲンの好セーブやシュート精度の欠如により得点には至らなかった。

一方のバルセロナもパウリーニョやスアレスを中心にチャンスを作ったが、GK ケイラー・ナバスの好守に阻まれた。結果として前半は 0-0 で終了したものの、内容としてはレアル・マドリードがやや優勢であった。

後半に入ると試合の流れは大きく変化した。54 分にはラキティッチのドリブル突破を起点とした速攻からスアレスが先制点を挙げた。さらに 64 分にはカルバハルがペナルティエリア内でハンドを犯して退場処分となり、バルセロナが PK を獲得した。この PK をメッシが決め、バルセロナが 2 点差に広げた。

数的不利となったレアル・マドリードは攻撃の勢いを失い、後半はバルセロナがボール保持率と試合の主導権を握った。試合終了間際の 90+3 分には、メッシのアシストから途中出場のアレイシ・ビダルが追加点を決め、試合は 0-3 で終了した。

以上より、本試合は「前半はレアル・マドリード優勢、後半はバルセロナ優勢」という流れで推移した試合である。そのため HPUS および HPUS+ の時系列推移においても、前半にはレアル・マドリード側で比較的大きなピークが現れ、後半にはバルセロナ側で高い値が観測されることが期待される。また、54 分の先制点、64 分の PK 獲得および追加点、90+3 分の 3 点目付近では、バルセロナ側の HPUS/HPUS+ が大きく上昇すると考えられる。

2 課題 2：自前モデルの学習

学習には OpenSTARLab の Event モジュールを利用した。

モデルには FMS を使用し，学習済みモデルとの公平な比較を行うため，対象試合および評価方法は ex4 と同一とした。

実験は Google Colaboratory 上で実施した。計算資源および実行時間の制約上，エポック数を大きくすると学習が終了しない場合があったため，本課題では全ての設定で num_epoch=2 に統一した。また，test オプションについてもデフォルト設定（True）のままとした。

主な学習設定を表 1 に示す。

表 1: 主な学習設定

項目	設定値
モデル	FMS
学習データ	Spain / Spain + England
seq_len	9 または 40
num_epoch	2
test	True
評価試合	match id = 2565711

3 課題 3：同一試合への推論

学習後，各モデルを用いて対象試合（match id = 2565711）に対する推論を実施した。

推論結果から予測イベント列を生成し，実イベントとの比較を行った。また，予測結果を用いて HPUS および HPUS+ を算出し，試合展開との対応関係について分析した。

さらに，配布済み NMSTPP モデルによる結果と比較することで，モデル変更，データ拡張，ハイパーパラメータ変更が予測性能や試合解釈に与える影響を評価した。

4 課題 4：可視化分析と比較・考察

4.0.1 loss_df の比較と考察

表 2 より，配布済みモデルである NMSTPP が全ての評価指標において最も良い性能を示した。

特に行動予測性能を表す ACC_action は 0.7222，F1_action は 0.1746 であり，自前学習した FMS 系列モデルの ACC_action=0.6067，F1_action=0.0838 を大きく上回った。また位置予測誤差についても，NMSTPP の MAE_x=7.9559，MAE_y=16.4698 に対し，FMS 系列では MAE_x が 23~26，MAE_y が 28~52 程度となり，大幅に誤差が増加した。

この結果から，本課題の条件下では，自前学習した FMS モデルは対象試合におけるイベント系列の予測精度において，配布済み NMSTPP モデルに及ばなかったことが分かる。

その要因として、NMSTPP がサッカーイベントの時系列情報と空間情報を同時に扱うことを目的として設計されたモデルであるのに対し、FMS はより汎用的なサッカー基盤モデルとして提案されている点が考えられる。また、本課題では計算資源の制約から学習エポック数を 2 に設定しており、FMS が十分に収束していなかった可能性も考えられる。

表 2: 各モデルの性能比較（太字は最良値）

Model	train_loss	CEL_action	ACC_action	F1_action	MAE_deltaT	MAE_x	MAE_y
Baseline (NMSTPP)	4.5694	0.8936	0.7222	0.1746	3.0311	7.9559	16.4698
FMS	15.0803	1.4303	0.6067	0.0838	3.4783	23.3101	29.3373
FMS + England	15.2184	1.6031	0.6067	0.0838	3.4330	26.0723	37.0873
FMS + seq_len=40	15.2479	1.4526	0.6067	0.0838	3.0736	24.9410	52.4191
FMS + England + seq_len=40	15.3335	1.5045	0.6067	0.0838	3.4328	25.5011	28.2998

さらに、図 8 で示した予測イベント分布では、FMS 系列モデルはほぼ全てのイベントを short_pass (0.0) として予測していた。この結果は F1_action が低い値となったこととも整合しており、FMS モデルが行動種類の識別を十分に学習できていなかったことを示唆している。

一方で、後述する HPUS および HPUS+ の比較では、FMS モデルも前半のリアル・マドリード優勢、後半のバルセロナ優勢という試合全体の流れをある程度再現できていた。これは、個々のイベント予測精度は低くても、ポゼッション単位で見た攻撃傾向や試合展開の大局的な特徴は捉えられていた可能性を示している。

次に、FMS モデル同士の比較を行う。

表 3 より、England リーグの追加および seq_len 変更による改善効果は限定的であった。

まず、England リーグのデータを追加した場合 (FMS + England)、MAE_deltaT は 3.4783 から 3.4330 へわずかに改善したものの、CEL_action は 1.4303 から 1.6031 へ悪化し、位置予測誤差も増加した。学習データ量の増加のみでは性能向上に結び付かなかったことが分かる。England リーグと Spain リーグのプレースタイルの違いが影響した可能性もあるが、本実験結果のみから断定することはできない。

次に、seq_len を 9 から 40 へ拡張した場合 (FMS + seq_len=40)、MAE_deltaT は 3.0736 となり、FMS 系列の中で最も良い値を示した。これは長い履歴情報を利用することで、イベント発生間隔の予測に有効に働いた可能性がある。

しかしその一方で、MAE_y は 52.4191 まで増加し、位置予測性能は大きく悪化した。長い履歴情報が必ずしも空間位置予測に有効ではなく、限られた学習条件下では逆に予測を不安定にした可能性が考えられる。

さらに、England リーグ追加と seq_len=40 を同時に適用した場合 (FMS + England + seq_len=40) は、MAE_y が 28.2998 となり、FMS 系列の中では比較的良好な結果を示した。しかし ACC_action や F1_action には改善が見られず、全体として大幅な性能向上には至らなかった。

表 3: FMS モデル間の性能比較（太字は FMS 系で最良値）

Model	train_loss	CEL_action	ACC_action	F1_action	MAE_deltaT	MAE_x	MAE_y
FMS	15.0803	1.4303	0.6067	0.0838	3.4783	23.3101	29.3373
FMS + England	15.2184	1.6031	0.6067	0.0838	3.4330	26.0723	37.0873
FMS + seq_len=40	15.2479	1.4526	0.6067	0.0838	3.0736	24.9410	52.4191
FMS + England + seq_len=40	15.3335	1.5045	0.6067	0.0838	3.4328	25.5011	28.2998

以上より、本課題で試した範囲では、

- 配布済み NMSTPP モデルが最も高い予測性能を示した
- FMS モデルは試合展開の大局的傾向は捉えられたが、イベント単位の予測精度では NMSTPP に及ばなかった
- England リーグ追加による効果は限定的であった
- seq_len 拡大は時間予測には有効であったが、位置予測には必ずしも有効ではなかった
- 学習データやパラメータ変更のみでは、FMS の性能向上は確認できなかった

という結果が得られた。

4.0.2 HPUS プロットの比較考察

ex4 において、配布済みモデルである NMSTPP を用いて推論した結果から算出した HPUS プロットを図 1 に示す。また、自前学習した FMS モデルによる HPUS プロットを図 2 に示す。

対象試合は前半をレアル・マドリードが優勢に進め、後半はバルセロナが主導権を握り 3 得点を挙げて勝利した試合であった。そのため HPUS においても、前半は Home（レアル・マドリード）側の値が高く、後半は Away（バルセロナ）側の値が高くなることが期待される。

図 1 より、NMSTPP モデルでは前半に両チームの HPUS が複数回上昇しており、25～40 分付近にはレアル・マドリードとバルセロナの双方で攻撃機会が発生している様子が確認できる。これは実際の試合において、レアル・マドリードがロナウドやベンゼマを中心に決定機を作る一方で、バルセロナもパウリーニョやスアレスを中心に得点機会を作っていた状況と対応している。

さらに後半では、54 分のスアレスによる先制点以降に Away（バルセロナ）の HPUS が上昇し、80 分以降にも大きなピークが確認できる。これは 64 分の PK による追加点や、90+3 分の 3 点目を含む試合終盤の攻勢を反映していると考えられる。したがって NMSTPP は、試合の主導権の変化や得点機会の増加を比較的適切に表現できているといえる。

一方、図 2 に示す FMS モデルでは、前半を通して Home（レアル・マドリード）の HPUS が高く推移しており、前半にレアル・マドリードが優勢であった試合展開をよく反映している。特に前半の HPUS 推移については、NMSTPP よりも実際の試合内容に近い傾向が見られた。

しかし後半では、60 分付近で Away（バルセロナ）の HPUS が上昇するものの、その後は両チームとも急激に低下している。実際の試合ではバルセロナが数的優位を活かして攻撃を継続し、終盤にも追加点を挙げていることから、FMS は後半の継続的な攻撃優勢や得点機会の増加を十分には表現できていないと考えられる。

以上より、FMS モデルは試合全体の大まかな流れ（前半レアル優勢、後半バルセロナ優勢）を捉えることはできているものの、得点に直結する重要な局面や試合終盤の攻撃支配を表現する能力は NMSTPP に及ばなかった。特に NMSTPP では得点場面付近で明確なピークが観測されており、HPUS を用いた試合展開の可視化という観点では NMSTPP の方が実際の試合内容を忠実に反映していると考えられる。




図 1: HPUS プロット (配布済みモデル NMSTPP モデル)




図 2: HPUS プロット (FMS モデル変更)

4.0.3 FMS モデル間の比較

図 3 に、各 FMS モデルから算出した HPUS プロットを示す。

全体的に見ると、4つの設定はいずれもピークが現れる時間帯やグラフ形状がほぼ一致しており、前半はレアル・マドリード優勢、後半はバルセロナ優勢という試合展開を同様に表現していることが分かる。したがっ


て、England リーグの追加や seq_len の変更は、HPUS が示す試合展開の時系列パターンには大きな影響を与えなかったと考えられる。

一方で、HPUS の絶対値には違いが見られた。FMS, FMS + England, FMS + England + seq_len=40 では最大値が概ね 100 前後で推移したのに対し、FMS + seq_len=40 のみ最大値が約 30 程度まで低下している。


この結果は、seq_len を 40 へ拡張したことで予測確率分布が変化し、HPUS 計算に用いられる行動確率や位置確率の期待値が小さくなったためと考えられる。実際に表 3 を見ると、FMS + seq_len=40 では MAE_deltaT が 3.0736 と最も良好である一方、MAE_y は 52.4191 と大きく悪化している。すなわち、長い履歴情報は時間予測には有効であったが、位置予測には悪影響を与えていた可能性がある。

また、England リーグの追加によって HPUS のスケールはわずかに変化したものの、グラフ形状やピーク位置には大きな変化が見られなかった。loss_df においても大幅な性能向上は確認できなかったことから、今回の設定ではデータ量の増加よりもモデル構造や学習条件の影響の方が大きかったと考えられる。


以上より、本課題で試した範囲では、データ拡張や seq_len 変更によって HPUS の絶対値は変化したものの、試合展開を表現する時系列パターン自体には大きな変化は見られなかった。




(a) モデル変更 (FMS)



(b) FMS + Spain + England



(c) FMS + seq_len=40



(d) FMS + データ拡張 + seq_len=40

図 3: 自前学習 (FMS ベース) の各条件における HPUS プロット比較

4.0.4 HPUS+ プロットの比較考察

HPUS はポゼッション全体の有効性を評価する指標であるのに対し、HPUS+ はシュートやクロスといった攻撃的アクションで終了したポゼッションのみを対象とする指標である。そのため HPUS+ は、実際の得点機会や決定機をより直接的に反映すると考えられる。

ex4 において配布済みモデル NMSTPP を用いて推論した結果から得られた HPUS+ プロットを図 4 に、自前学習した FMS モデルによる HPUS+ プロットを図 5 に示す。

前半の挙動を見ると、配布済みモデル (NMSTPP) では Home (レアル・マドリード) と Away (FC バルセロナ) が交互にスパイクを形成しており、両チームがそれぞれ決定機を作っていたことが反映されている。特に 30~40 分付近では Away (バルセロナ) 側にも比較的大きなピークが見られ、パウリーニョの決定機など実際の試合内容と対応していると考えられる。

一方、自前モデル (FMS) では試合開始直後に Home (レアル・マドリード) が 20 を超える大きなピークを記録している。これは開始 2 分のクリスティアーノ・ロナウドのオフサイドとなった得点シーンや、その後のレアル・マドリードによる攻勢を強く反映した結果であると考えられる。また前半終了間際にも Home 側に大きなピークが観測されており、ベンゼマのヘディングシュートなど前半の決定機を反映している可能性が高い。

したがって両モデルとも「前半はレアル・マドリード優勢」という試合展開を捉えているが、FMS モデルの方が前半の決定機をより強く評価する傾向が見られた。

後半については、両モデルとも Home (レアル・マドリード) の値が低下し、Away (FC バルセロナ) の値が上昇している。これは 54 分のスアレスによる先制点、64 分のメッシによる PK 成功を含む、バルセロナ優勢の試合展開と整合している。

しかし両モデルには違いも見られる。NMSTPP では 60 分以降も Away 側のスパイクが継続的に観測され、80 分以降には大きなピークが出現している。これは試合終盤まで継続したバルセロナの攻撃支配や、90+3 分のビダルによる追加点を反映していると考えられる。

一方 FMS では 60 分付近で Away 側の値が大きく上昇するものの、その後は両チームとも急激に低下している。そのため試合終盤におけるバルセロナの継続的な攻撃優勢や 3 点目につながる攻撃シーケンスを十分に表現できていないと考えられる。

以上より、FMS モデルは前半の決定機の評価には優れている一方で、NMSTPP モデルは試合全体を通じた攻撃の継続性や終盤の得点機会をより適切に反映していると考えられる。




図 4: HPUS プロット (配布済みモデル NMSTPP モデル)




図 5: HPUS プロット (FMS モデル変更)

4.0.5 FMS モデル間の比較

図 6 に、各 FMS モデルから算出した HPUS+ プロットを示す。

全体的に見ると、4つの設定はいずれもピークが出現する時間帯やグラフの形状がほぼ一致していた。特に前半序盤のレアル・マドリード優勢の局面や、後半 60 分付近のバルセロナ優勢への移行は全ての設定で共通

して観測された。

このことから、England リーグの追加や seq_len の変更は、試合展開そのものを表現する時系列パターンには大きな影響を与えなかったと考えられる。


一方で、HPUS+ の絶対値には違いが見られた。FMS, FMS + England, FMS + England + seq_len=40 では最大値が 20 前後で推移したのに対し、FMS + seq_len=40 のみ最大値が約 7 まで低下した。

HPUS+ はシュートやクロスといった攻撃的アクションに対する予測確率から算出されるため、この差はモデルが出力する行動確率分布の変化に起因すると考えられる。特に seq_len を 40 へ拡張した場合には、長期的な文脈情報を参照できる一方で、攻撃的アクションの予測確率が全体的に低下した可能性がある。


実際に表 3 を見ると、FMS + seq_len=40 では MAE_deltaT が最も小さく時間予測性能は改善している一方で、MAE_y は大幅に悪化している。したがって、長い履歴情報はイベント発生タイミングの予測には有効であったものの、攻撃アクションの発生位置や種類の予測には必ずしも有効ではなかったと考えられる。

また、England リーグの追加によって HPUS+ のスケールはわずかに変化したものの、グラフ形状やピーク位置には大きな変化が見られなかった。loss_df においても大幅な性能向上は確認できなかったことから、本課題で用いた学習条件では、データ量の増加による恩恵は限定的であったと考えられる。


以上より、FMS モデルに対するデータ拡張および seq_len 変更は、HPUS+ が示す試合展開の傾向には大きな影響を与えなかった。一方で、HPUS+ の絶対値や予測確率分布には変化が生じており、これらの設定変更はモデル内部の予測特性には一定の影響を与えていたことが示唆される。




(a) モデル変更 (FMS)



(b) FMS + Spain + England



(c) FMS + seq_len=40



(d) FMS + データ拡張 + seq_len=40

図 6: 自前学習 (FMS ベース) の各条件における HPUS プロット比較

4.0.6 予測イベント分布

図 7 および図 8 より、予測イベント分布には大きな違いが見られた。

配布済み NMSTPP モデルでは、予測イベントの大部分は 0.0 (short_pass) であったものの、3.0 (dribble) や 4.0 (long_pass) などとも一定数予測されていた。実際のイベント分布と完全には一致していないが、複数種類のアクションを予測し分ける能力を有していることが確認できる。

一方、自前学習した FMS モデルでは、全ての予測イベントが 0.0 (short_pass) となった。実際の試合データには dribble, long_pass, shot など多様なアクションが存在しているにもかかわらず、モデルはそれらを全く予測できていない。さらに、England リーグのデータ追加や seq_len の変更を行った場合でも同様の結果となり、予測分布に変化は見られなかった。

この結果は、FMS モデルが学習データ中で最も頻繁に出現する short_pass へ予測が集中する状態に陥った可能性を示している。サッカーのイベントデータでは short_pass の出現頻度が非常に高く、学習が不十分な場合には、その他のアクションを無視して多数派クラスのみを予測することで損失をある程度小さくできてしまう。

実際に表 2 を見ると、FMS 系列モデルの ACC_action は 0.6067 となっている。これは一見すると極端に低い値ではないが、short_pass がデータ全体の大部分を占めている場合、常に short_pass を予測するだけでも一定の正解率を得られるためである。一方で F1_action は 0.0838 と非常に低く、多様なアクションを識別できていないことが分かる。このことから、FMS モデルは実際にはイベント分類能力を十分に獲得できていなかったと考えられる。

興味深い点として、イベント分類性能は低かったにもかかわらず、HPUS および HPUS+ の時系列推移は実際の試合展開をある程度反映していた。これは HPUS が単一イベントの分類結果だけでなく、予測された位置情報や時間情報も利用して計算されるためであると考えられる。すなわち、FMS モデルはアクション種類の予測には失敗していたものの、試合全体の攻撃・守備の流れやポゼッションの推移については一定程度捉えられていた可能性がある。

以上より、本課題で学習した FMS モデルは、試合の大局的な流れを表現する能力は有していたものの、個々のイベントの種類を識別する能力は十分ではなく、特に行動分類において大きな課題が残る結果となった。

以上の結果は、loss_df において FMS 系列モデルの ACC_action が 0.6067 である一方、F1_action が 0.0838 と極めて低かった結果とも一致している。すなわち、モデルは多数派クラスである short_pass に予測を集中させることで一定の正解率を維持していたが、多様なイベントを識別する能力は獲得できていなかった。その結果として、HPUS や HPUS+ では試合全体の流れをある程度再現できたものの、イベント単位の予測精度では NMSTPP モデルとの差が大きく表れたと考えられる。




図 7: 予測イベント vs 実イベント分布 (配布済みモデル NMSTPP モデル)




図 8: 予測イベント vs 実イベント分布 (FMS モデル変更)

5 課題 5：発展課題（複数設定の比較）

本課題では、FMS モデルをベースとして、

1. FMS
2. FMS + England
3. FMS + seq_len=40
4. FMS + England + seq_len=40

の 4 種類の設定で学習を行い、それぞれの性能を比較した。

5.1 各設定の比較

表 3 より、FMS 系列モデル間では大きな性能差は見られなかった。

まず、England リーグのデータを追加した設定では、学習データ量の増加による汎化性能向上を期待したが、ACC_action および F1_action に改善は見られなかった。また MAE_x および MAE_y はむしろ悪化しており、本課題の条件ではデータ拡張による効果は限定的であった。

次に、seq_len を 9 から 40 へ拡張した設定では、MAE_deltaT が 3.0736 となり、FMS 系列の中で最も良い結果を示した。これは長い履歴情報を利用できることで、イベント発生間隔の予測に有利に働いたためと考えられる。

一方で、MAE_y は 52.4191 と大幅に悪化した。長い系列を扱うことで遠い過去の情報の影響が強くなり、位置予測においてノイズが増加した可能性がある。

さらに、England リーグ追加と seq_len 拡張を同時に行った設定では、MAE_y が 28.2998 となり、FMS 単体より改善が見られた。しかし ACC_action や F1_action に変化はなく、全体的な性能向上には至らなかった。

5.2 HPUS および HPUS+ から見た比較

HPUS および HPUS+ のプロットを比較すると、4 つの設定はいずれも非常によく似た時系列パターンを示した。

前半はリアル・マドリッド優勢、後半はバルセロナ優勢という試合全体の流れは、全ての設定で共通して観測された。また、60 分前後に Away 側の値が上昇する傾向も共通していた。

一方で、HPUS や HPUS+ の絶対値には差が見られた。特に seq_len=40 を単独で適用した場合には、HPUS および HPUS+ の最大値が他設定より小さくなった。しかし時系列パターン自体はほとんど変化しておらず、試合展開の解釈に大きな差は見られなかった。

このことから、今回試したデータ拡張や seq_len 変更は、HPUS のスケールには影響を与えるものの、試合展開の表現能力には大きな影響を与えなかったと考えられる。

5.3 良かった設定と改善しなかった設定

今回の結果から、最も良い設定は

FMS + seq_len=40

であると考えられる。

その理由は、FMS 系列モデルの中で最も低い MAE_deltaT を達成し、イベント発生タイミングの予測精度が改善されたためである。また、HPUS および HPUS+ の時系列パターンも他設定と同等に試合展開を表現できていた。

一方で、最も改善効果が小さかった設定は

FMS + England

であった。

学習データ量の増加による性能向上を期待したものの、ACC_action や F1_action に改善は見られず、位置予測誤差も増加した。England リーグと Spain リーグではプレイスタイルや試合テンポが異なるため、追加したデータが必ずしも対象試合の特徴学習に有効ではなかった可能性がある。

5.4 総合考察

本課題では、モデル構造、学習データ量、および系列長の変更による影響を検証した。

しかし、どの設定においてもイベント予測は short_pass に大きく偏っており、ACC_action および F1_action の改善は見られなかった。また、HPUS および HPUS+ は試合展開をある程度再現できていたものの、配布済み NMSTPP モデルと比較すると予測精度には大きな差が存在した。

その要因として、

- 学習エポック数を 2 に制限したこと
- test=True の設定で学習データ量が限定されていたこと
- FMS が本来大規模データでの学習を前提としたモデルであること

が考えられる。

今後は、

- 学習エポック数の増加
- test=False による全データ学習
- クラス不均衡への対策
- 他モデル（LEM や Seq2Event）との比較

を行うことで、さらなる性能向上が期待できる。