

B4 輪講 2026：EX6 レポート

加藤 稔之典

2026 年 6 月 15 日

本課題では、Soccer Trajectory Prediction Challenge 2025 のデータを用いて、サッカーにおける選手とボールの将来軌道を予測する。RNN モデルを用いたベースラインを実行し、入力軌道、Ground Truth (GT)、予測結果を比較することで、時系列データとしてのサッカーの動きの特徴を理解し、モデルの入力条件の違いが予測精度に与える影響を分析することを目的とする。

1 課題 1：軌道の可視化・理解

1.1 実験設定と誤差算出スクリプト

ベースラインとして、配布されたノートブックに基づき以下のコマンドで RNN モデルを実行した。

```
python main.py --n_epoch 10 --model RNN --burn_in 30 -t_step 60
```

本設定では、最初の 30 フレームを入力軌道（過去）として使い、60 フレーム目までの軌道を扱う。すなわち、過去 30 フレームの文脈から将来の 30 フレームを予測するタスクである。

評価対象として 01.csv, 02.csv, 03.csv の 3 ファイルを選定した。それぞれの入力データ (./test_old/input/*.csv), GT データ (./test_old/gt/*.csv), および予測結果 (./results/test/submission/*.csv) を読み込み、ボール・左チーム・右チーム個別の平均誤差および最大誤差を特定するため、プログラムコード 1.1 に示す解析スクリプト calculate_detailed_errors.py を作成・実行した。

calculate_detailed_errors.py

```
1 import pandas as pd
2 import numpy as np
3 import os
4
5 target_files = ['01.csv', '02.csv', '03.csv']
6
7 print(f"{'File':<10} | {'Ball Error':<12} | {'Left Team Error':<16} | {'Right Team
  ↳ Error':<17}")
8 print("-" * 65)
9
10 for file_name in target_files:
11     pred = pd.read_csv(f'./results/test/submission/{file_name}')
12     gt = pd.read_csv(f'./test_old/gt/{file_name}')
13     inp = pd.read_csv(f'./test_old/input/{file_name}')
```

```

14
15 start_idx = len(inp)
16 gt_slice = gt.iloc[start_idx : start_idx + len(pred)].reset_index(drop=True)
17
18 # ボールの誤差計算
19 b_err_seq = np.sqrt((pred['b_x'] - gt_slice['b_x'])**2 + (pred['b_y'] -
    ↳ gt_slice['b_y'])**2)
20 b_mean_err = b_err_seq.mean()
21
22 # 左チームの誤差計算
23 l_cols_x = [c for c in pred.columns if c.startswith('l') and c.endswith('_x')]
24 l_err_list = []
25 max_l_err = 0
26 max_l_player = ""
27 max_l_frame = -1
28
29 for cx in l_cols_x:
30     cy = cx.replace('_x', '_y')
31     err_seq = np.sqrt((pred[cx] - gt_slice[cx])**2 + (pred[cy] - gt_slice[cy])**2)
32     l_err_list.append(err_seq.mean())
33
34     if err_seq.max() > max_l_err:
35         max_l_err = err_seq.max()
36         max_l_player = cx.replace('_x', '')
37         max_l_frame = err_seq.idxmax() + 1
38
39 l_mean_err = np.mean(l_err_list)
40
41 # 右チームの誤差計算
42 r_cols_x = [c for c in pred.columns if c.startswith('r') and c.endswith('_x')]
43 r_err_list = []
44 max_r_err = 0
45 max_r_player = ""
46 max_r_frame = -1
47
48 for cx in r_cols_x:
49     cy = cx.replace('_x', '_y')
50     err_seq = np.sqrt((pred[cx] - gt_slice[cx])**2 + (pred[cy] - gt_slice[cy])**2)
51     r_err_list.append(err_seq.mean())
52
53     if err_seq.max() > max_r_err:
54         max_r_err = err_seq.max()
55         max_r_player = cx.replace('_x', '')
56         max_r_frame = err_seq.idxmax() + 1
57
58 r_mean_err = np.mean(r_err_list)
59
60 # 結果の出力

```

```

61     print(f"{file_name:<10} | {b_mean_err:<12.4f} | {l_mean_err:<16.4f} | \
        ↳ {r_mean_err:<17.4f}")
62
63     # 各ファイルにおける最大誤差
64     if b_err_seq.max() > max_l_err and b_err_seq.max() > max_r_err:
65         print(f"  -> [最大誤差] 対象: ボール, 誤差: {b_err_seq.max():.4f}, フレーム: \
        ↳ {b_err_seq.idxmax()+1}")
66     elif max_l_err > max_r_err:
67         print(f"  -> [最大誤差] 対象: 選手 {max_l_player}, 誤差: {max_l_err:.4f}, \
68 フレーム: {max_l_frame}")
69     else:
70         print(f"  -> [最大誤差] 対象: 選手 {max_r_player}, 誤差: {max_r_err:.4f}, \
71 フレーム: {max_r_frame}")
72     print("-" * 65)

```

1.2 可視化結果と定量評価

公式評価スクリプトによる全体の評価、および上記スクリプトから得られた詳細な誤差データを表 1 に示す。また、各ファイルにおけるピッチ上の軌道可視化結果を図 1～3 に示す。

表 1: 課題 1（ベースライン：入力 30 / 予測 30）におけるファイル別・対象別誤差

ファイル名	ボール平均誤差	左チーム平均誤差	右チーム平均誤差	最大誤差の対象 (値 / フレーム)
01.csv	10.9911	4.9919	3.0716	ボール (21.4533 / 第 30 フレーム)
02.csv	8.0792	6.4411	6.6516	選手 r9 (21.2833 / 第 30 フレーム)
03.csv	13.1184	5.5983	5.6093	ボール (24.9243 / 第 24 フレーム)
全体平均誤差 (Average Error): 6.0982		最終点誤差 (Endpoint Error): 10.8453		




図 1: 01.csv における軌道予測結果（ベースライン）




図 2: 02.csv における軌道予測結果（ベースライン）




図 3: 03.csv における軌道予測結果（ベースライン）

1.3 考察

すべてのファイルにおいて、ボールの平均誤差（8.0～13.1）は選手の平均誤差（3.0～6.6）よりも有意に大きい。人間（選手）は質量に伴う慣性があるため、過去の入力軌道から滑らかな移動トレンドをモデルが捉えやすく、予測値 (Pred) と真値 (GT) が重なりやすい。一方、ボールは選手によるキック（パス、シュート、クリア等）によって一瞬で進行方向や速度がガラリと変わる「不連続な変化」を起こす性質がある。過去のデータのみ依存する RNN モデルにとって未来の突発的なキックを予知することは不可能であり、これがボールの予測精度を大きく低下させる要因であると考えられる。

2 課題 2：特徴量・入力条件の変更

2.1 実験条件の設定

入力フレーム数 (`--burn.in`) を変更することで、AI に与える過去の情報量と未来の予測期間の長さが予測精度に与える影響を評価した。総フレーム数 (`-t.step 60`) は固定のまま、以下の 2 つの条件で実験を行った（条件の対比を表 2 に示す）。

1. 短縮設定 (`--burn.in 20`): 過去 20 フレームを入力し、将来 40 フレームを予測する。
2. 延長設定 (`--burn.in 40`): 過去 40 フレームを入力し、将来 20 フレームを予測する。

表 2: 課題 2 における実験条件の変更

実験パターン	入力フレーム数 (--burn_in)	予測フレーム数 (未来の長さ)	総フレーム数 (-t_step)
元の設定 (ベースライン)	30 フレーム	30 フレーム	60
条件 1 (短縮設定)	20 フレーム	40 フレーム	60
条件 2 (延長設定)	40 フレーム	20 フレーム	60

2.2 実験結果（可視化および評価値比較）

短縮設定 (burn_in 20) における軌道可視化結果を図 4～6 に，延長設定 (burn_in 40) における結果を図 7～9 に示す。また，ベースラインを含む 3 条件の定量誤差の比較を表 3 に示す。




图 4: 01.csv (burn_in 20)




图 5: 02.csv (burn_in 20)




图 6: 03.csv (burn_in 20)




图 7: 01.csv (burn_in 40)




图 8: 02.csv (burn_in 40)




图 9: 03.csv (burn_in 40)

表 3: 条件変更前後の詳細誤差比較

ファイル名	設定区分 (burn_in)	ボール誤差	左チーム誤差	右チーム誤差	最大誤差の対象 (値 / フレーム)
01.csv	短縮設定 (20)	14.2287	8.8013	9.1041	選手 r6 (40.1153 / 第 35 フレーム)
	ベースライン (30)	10.9911	4.9919	3.0716	ボール (21.4533 / 第 30 フレーム)
	延長設定 (40)	6.8764	3.4051	1.9349	ボール (18.9862 / 第 20 フレーム)
02.csv	短縮設定 (20)	11.7363	7.8921	7.8959	ボール (28.9505 / 第 40 フレーム)
	ベースライン (30)	8.0792	6.4411	6.6516	選手 r9 (21.2833 / 第 30 フレーム)
	延長設定 (40)	6.5032	4.4143	4.6943	選手 r6 (16.3764 / 第 20 フレーム)
03.csv	短縮設定 (20)	14.5038	9.7134	11.4321	選手 r11 (43.1282 / 第 40 フレーム)
	ベースライン (30)	13.1184	5.5983	5.6093	ボール (24.9243 / 第 24 フレーム)
	延長設定 (40)	8.9563	3.9193	4.0936	ボール (21.0377 / 第 20 フレーム)
全体総合指標:					
- 短縮設定 (20): Average Error = 9.1928, Endpoint Error = 21.1860 - ベースライン (30): Average Error = 6.0982, Endpoint Error = 10.8453 - 延長設定 (40): Average Error = 4.2072, Endpoint Error = 8.0443					

2.3 考察

ベースラインと比較して短縮設定 (burn_in 20) では、すべてのファイル・すべての対象において誤差が著しく悪化した (全体平均: 6.09 → 9.19)。特に選手の誤差拡大が顕著であり、01.csv の r6 や 03.csv の r11 では 40m を超える致命的な最大誤差を記録した。これは、入力 が 20 フレームに減ったことで直前の正確な移動ベクトル (速度・加速度) を RNN が蓄積しきれなかったこと、予測期間が 40 フレームに長期化したことで、RNN の自己回帰的な予測性質により、初期の微小なズレが後半にかけて蓄積したことが原因であると考えられる。

一方で、burn_in 40 に延長した設定ではすべての指標が大幅に改善した (全体平均: 6.09 → 4.20)。過去を 40 フレーム (約 4 秒) にわたり長く観察できたことで、モデルの内部状態に正確な文脈を載せることができ、さらに予測期間が 20 フレームに短縮されたためと考えられる。

入力フレームを 40 に増やしたことでボールの平均誤差も大きく減少したが (例: 01.csv では 10.99 → 6.87)、ボールの最大誤差自体は依然として 18m~21m の高い値が残った。これは過去をどれほど長く見ても「予測期間中に発生する突発的なキック」を予知することは本質的に困難であることを示していると考えられる。